



CARRERA DE ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL

MEMORIA DEL TRABAJO FINAL

Desarrollo de un *pipeline* de aprendizaje continuo para chatbots basados en PLN

Autor:

Ing. Porra Bustos, Matias Exequiel (UTN-FRLR)

Director:

Dr. Ing. Cárdenas Rodrigo (FIUBA)

Jurados:

Esp. Ing. Torrent Leandro (FIUBA)

Nombre del jurado 2 (pertenencia)

Nombre del jurado 3 (pertenencia)

*Este trabajo fue realizado en la Ciudad Autónoma de Buenos Aires,
entre mayo de 2024 y abril de 2025.*

Resumen

El presente trabajo propone una solución avanzada para la automatización de la comunicación empresarial, orientada a emprendedores y pequeñas empresas. El sistema desarrollado consiste en un chatbot que integra técnicas de procesamiento del lenguaje natural (PLN) y gestión de bases de datos, articulado en un pipeline de aprendizaje continuo. Este chatbot está diseñado para optimizar la interacción con los clientes, ya que genera respuestas precisas y relevantes a sus consultas en lenguaje natural. Además, el sistema se retroalimenta de las interacciones previas para mejorar su rendimiento de manera constante y adaptarse mejor a las necesidades de los usuarios.

Agradecimientos

A mi novia por apoyo incondicional durante todo el proceso de desarrollo de este trabajo.

A mi familia, por estar siempre presente.

A mi tutor, por su guía y su conocimiento.

A Michael Schreiber por sus grandes aportes y guía en mi formación profesional en IA.

Índice general

Resumen	I
1. Introducción general	1
1.1. Motivación	1
1.1.1. ¿Qué es un chatbot?	1
1.1.2. ¿Por qué un chatbot?	1
1.2. Alcance y objetivos	2
1.2.1. Objetivos principales	2
1.2.2. Alcance del trabajo	3
1.3. Estado del arte	3
1.3.1. Recursos para chatbots	3
Servicios basados en APIs	3
Modelos locales	4
1.3.2. Tendencias actuales	4
2. Introducción específica	5
2.1. Requerimientos	5
2.2. Modelos de inteligencia artificial para PLN	6
2.2.1. Modelos de Lenguaje modernos	6
2.3. Modelos de chatbots: RAG vs Fine-Tuning	7
2.3.1. Retrieval Augmented Generation (RAG)	7
2.3.2. Fine-Tuning	8
2.3.3. Ventajas y desventajas de los modelos RAG y Fine-Tuning	9
3. Diseño e implementación	11
3.1. Diseño de la arquitectura	11
3.1.1. Propuestas de implementación	11
3.1.2. Problemas y mitigaciones	14
3.1.3. Elección de la arquitectura de chatbot	15
3.2. Arquitectura final propuesta	16
3.2.1. Tecnologías suplementarias	17
3.2.2. Funcionamiento general	17
3.3. Implementación	19
3.3.1. Preparación de los datos de contexto	19
3.3.2. Sistema de reentrenamiento con historiales y evaluación automatizada de interacciones	20
3.4. Despliegue de la interfaz de pruebas	22
4. Ensayos y resultados	25
4.1. Evaluación de escenarios del chatbot	25
4.1.1. Escenario 1: Interacción básica	25
4.1.2. Escenario 2: Manejo de errores	25
4.1.3. Escenario 3: Consultas complejas	25

4.2. Optimización	25
4.2.1. Ajuste de parámetros del modelo	26
4.2.2. Configuraciones del entorno de ejecución	26
4.2.3. Impacto en el rendimiento	26
4.3. Análisis de resultados	26
4.3.1. Métricas de evaluación	26
4.3.2. Comparación entre escenarios	26
4.3.3. Interpretación de resultados	26
4.4. Identificación de fallos y mejoras propuestas	26
4.4.1. Principales errores detectados	27
4.4.2. Limitaciones del sistema actual	27
4.4.3. Sugerencias para mejoras futuras	27
Bibliografía	29

Índice de figuras

1.1. Relación entre los objetivos centrales.	2
2.1. Diagrama de flujo de una consulta en un chatbot con arquitectura RAG.	8
3.1. Diagrama general del sistema para la versión 1.	12
3.2. Diagrama general del sistema para la versión 2.	13
3.3. Ejemplo de redefinición de pregunta.	14
3.4. Frontend del chatbot.	16
3.5. Diagrama general del flujo del pipeline.	17
3.6. Diagrama de flujo de funcionamiento.	19
3.7. Diagrama de flujo de observación de métricas.	21
3.8. métricas por categoría.	21
3.9. Ejemplo frontend, métricas para preguntas buenas y malas	22
3.10. frontend creado para administracion de contextos.	23

Índice de tablas

2.1. Ventajas y desventajas de los modelos RAG y Fine-Tuning.	9
4.1. Resultados comparativos de evaluación del chatbot.	26

Capítulo 1

Introducción general

En este capítulo se presentan las motivaciones que impulsaron el desarrollo del sistema, diseñado para automatizar la comunicación entre emprendedores y sus clientes. Se ofrece, además, una explicación detallada sobre qué son los chatbots y las razones por las que su uso resulta fundamental en este contexto. Finalmente, se describen los objetivos principales del trabajo, centrados en la facilidad de implementación y en la mejora de la eficiencia operativa, junto con el alcance definido durante la planificación.

1.1. Motivación

El sistema desarrollado en el presente trabajo surge de la necesidad de proporcionar a emprendedores una herramienta que les permita automatizar la comunicación con sus clientes de manera eficiente y personalizada. Esta herramienta les ofrece una ventaja competitiva al optimizar la gestión de sus interacciones con los usuarios y les permite mejorar la eficiencia operativa, además de reducir los costos asociados a la atención al cliente.

1.1.1. ¿Qué es un chatbot?

Un chatbot es un programa de software que emplea técnicas de Procesamiento del Lenguaje Natural (PLN) [1], para interpretar y contestar automáticamente las consultas de los usuarios de manera coherente y eficiente. Esto facilita la automatización de interacciones comunes y mejora la experiencia del cliente.

1.1.2. ¿Por qué un chatbot?

A continuación, se destacan algunas de las razones principales por las que un chatbot es la solución ideal para este trabajo:

- Disponibilidad 24/7: los chatbots están disponibles en todo momento, lo que les permite a las empresas atender consultas de sus clientes a cualquier hora del día.
- Reducción de costos: al automatizar la atención al cliente, los chatbots ayudan a las empresas a reducir los costos asociados al personal humano sin comprometer la calidad del servicio.
- Recolección de datos valiosos: los chatbots pueden recopilar y analizar información relevante sobre las interacciones con los clientes, lo que les permite a las empresas ajustar sus estrategias de manera eficiente.

- Optimización de tiempos de respuesta: la capacidad de generar respuestas inmediatas en función de consultas predefinidas optimiza los tiempos de respuesta.

1.2. Alcance y objetivos

1.2.1. Objetivos principales

El trabajo se enfoca en tres objetivos principales que se interrelacionan para ofrecer una solución integral a pequeños emprendedores. Cada uno de estos objetivos está orientado a asegurar que la herramienta sea accesible, fácilmente implementable y de bajo costo, para garantizar una experiencia eficiente y optimizada para las empresas que la adopten.

A continuación, se detallan los objetivos principales:

- Proporcionar acceso a pequeños emprendedores: desarrollar un sistema que sea de fácil adopción y pueda ser utilizado por pequeñas empresas, independientemente de sus conocimientos técnicos.
- Garantizar una fácil implementación: diseñar una solución replicable, de modo que cualquier empresa pueda contar con el chatbot simplemente al proporcionar el contexto necesario para su entrenamiento. No será necesario disponer de infraestructura compleja ni personal especializado.
- Reducir el costo de mantenimiento: proporcionar una herramienta con un bajo costo de mantenimiento, tanto en términos económicos como de tiempo, para que los emprendedores puedan centrarse en su negocio principal.




FIGURA 1.1. Relación entre los objetivos centrales.

1.2.2. Alcance del trabajo

Durante la planificación del trabajo se propusieron las siguientes actividades:

- Diseño, desarrollo e implementación de un *pipeline* completo para la creación y gestión de chatbots basados en PLN, con capacidad de aprendizaje continuo.
- Desarrollo de algoritmos para el preprocesamiento de información y generación de respuestas relevantes y coherentes.
- Establecimiento de métricas y procedimientos de evaluación para medir la calidad y eficacia de las respuestas del chatbot.
- Implementación de un sistema de retroalimentación que utilice los datos de interacciones con usuarios para mejorar el rendimiento del modelo.

El presente trabajo excluye:

- Desarrollo de interfaces de usuario avanzadas, por fuera de las básicas necesarias para probar el pipeline.
- Integración con sistemas externos, como bases de datos o plataformas de gestión de clientes.
- Implementación del sistema en un entorno productivo.
- Actividades de marketing o promoción del producto final.

1.3. Estado del arte

Los chatbots se han integrado en numerosos aspectos de la vida diaria y en diversos canales de comunicación. Se encuentran presentes en redes sociales como Facebook e Instagram, donde facilitan la interacción con empresas. Además, muchas organizaciones y entidades gubernamentales, han implementado chatbots para mejorar la atención al ciudadano. Plataformas como IBM Watson, Google Dialogflow y Microsoft Bot Framework permiten a las empresas crear chatbots personalizados con gran flexibilidad.

1.3.1. Recursos para chatbots

Servicios basados en APIs

Los servicios basados en API¹ simplifican la implementación de chatbots al ofrecer interfaces estandarizadas para acceder a funcionalidades avanzadas. Estos servicios permiten una mayor personalización y flexibilidad en el diseño de chatbots, que facilitan la integración con otros sistemas y plataformas. La utilización de APIs permite a las empresas adaptar las soluciones a sus necesidades específicas sin necesidad de desarrollar toda la infraestructura desde cero.

¹API (Interfaz de Programación de Aplicaciones) es un conjunto de reglas y protocolos que permite que diferentes aplicaciones se comuniquen entre sí.

Modelos locales

Los modelos locales como Llama 3.1, Phi 3, Gemma y Mistral son soluciones robustas que operan sin depender de servicios externos. Cada uno de estos ofrece características y ventajas específicas, como mayor control sobre los datos y la posibilidad de operar en entornos con restricciones de privacidad. Su uso es particularmente valioso cuando se requiere un alto nivel de personalización y seguridad en la gestión de datos.

1.3.2. Tendencias actuales

Cada vez más empresas optan por utilizar servicios basados en API, que han hecho más accesible y económico el despliegue de chatbots sofisticados. Estas herramientas simplifican la implementación y permiten la creación rápida de soluciones adaptadas a las necesidades específicas de cada empresa o entidad. Aunque los modelos locales son valiosos por su robustez y capacidad para operar sin depender de servicios externos, son útiles especialmente cuando se requiere un mayor control o confidencialidad.

Capítulo 2

Introducción específica

Este capítulo explora los requisitos fundamentales para el desarrollo de un sistema de chatbot, que abarcan aspectos funcionales, de documentación, pruebas, interfaz y rendimiento. Además, revisa los diferentes tipos de chatbots y modelos de inteligencia artificial, con énfasis en sus características y aplicaciones en el procesamiento de lenguaje natural.

2.1. Requerimientos

1. Requerimientos funcionales:

- a) El sistema debe ser capaz de procesar y comprender mensajes de texto entrantes.
- b) El chatbot debe poder proporcionar respuestas relevantes y precisas a las consultas de los usuarios.
- c) Los usuarios deben tener la posibilidad de interactuar con el chatbot a través de una interfaz de usuario.
- d) Se requiere una interfaz de usuario que facilite el proceso de reentrenamiento del chatbot mediante el uso de los historiales de conversación.

2. Requerimientos de documentación:

- a) Documentar detalladamente las tecnologías utilizadas y sus principales características, así como las particularidades de diseño de cada una.
- b) El sistema no almacenará datos personales de los usuarios, sino que se limitará a responder preguntas frecuentes. En caso de requerirse almacenamiento de datos, se utilizará una plataforma con medidas de seguridad integradas, como autenticación mediante logins con Google.
- c) Entregar una memoria técnica que contenga información detallada sobre la implementación del sistema, que incluya aspectos técnicos, arquitectura y decisiones de diseño.
- d) Proporcionar un registro de avance que documente los hitos alcanzados durante el desarrollo del proyecto, que contemple fechas de cumplimiento y descripciones de las tareas realizadas.

3. Requerimientos de Testing:

- a) Se llevarán a cabo pruebas en diferentes escenarios y con diferentes tipos de contexto de datos, para garantizar la fiabilidad y precisión del chatbot.

4. Requerimientos de la Interfaz:

- a) Se requiere una interfaz interactiva, que permita hacer preguntas y obtener respuestas en tiempo real dentro del mismo entorno de interacción.

5. Requerimientos de Rendimiento:

- a) Se establece un límite máximo de tiempo de respuesta de 1 minuto, para asegurar una experiencia satisfactoria para el usuario.

2.2. Modelos de inteligencia artificial para PLN

El procesamiento de lenguaje natural (PLN) ha avanzado significativamente gracias al desarrollo de diversas técnicas de inteligencia artificial. Estas se pueden clasificar en varias categorías, cada una con su propio enfoque y aplicación.

Modelos basados en reglas: estos modelos utilizan gramáticas y diccionarios para analizar el lenguaje. Aunque son efectivos en tareas específicas, su rigidez y la necesidad de una extensa programación manual limitan su aplicabilidad en contextos más amplios.

Modelos estadísticos: a medida que los datos comenzaron a acumularse, los modelos estadísticos, como los n-gramas, se convirtieron en populares. Estos modelos predicen la probabilidad de una palabra en función de las palabras anteriores. Sin embargo, su dependencia de datos limitados puede resultar en un contexto insuficiente, lo que afecta la calidad de las predicciones.

Modelos de aprendizaje profundo: con el auge del aprendizaje profundo, arquitecturas como RNN (Redes Neuronales Recurrentes), LSTM (Memoria a Largo Plazo) y transformers han revolucionado el PLN. Estos modelos pueden captar patrones complejos en grandes volúmenes de datos, lo que les permite realizar tareas como la traducción automática y la generación de texto de manera más efectiva.

2.2.1. Modelos de Lenguaje modernos

Modelos como BERT (Bidirectional Encoder Representations from Transformers) y GPT (Generative Pre-trained Transformer) han transformado el campo del procesamiento de lenguaje natural (PLN), al ofrecer enfoques innovadores para comprender y generar texto.

- **GPT:** este modelo utiliza técnicas de aprendizaje profundo para generar texto coherente y contextualmente relevante. Su capacidad para crear respuestas naturales ha revolucionado la interacción de los chatbots con los usuarios, lo que permite conversaciones más fluidas y precisas.
- **BERT:** a diferencia de otros modelos, BERT se centra en el análisis bidireccional del texto, lo que le permite entender el contexto de manera más

profunda. Esta característica mejora la identificación de intenciones y la respuesta a preguntas complejas, lo que ayuda a crear chatbots más competentes en diálogos matizados.

2.3. Modelos de chatbots: RAG vs Fine-Tuning

Los chatbots se pueden clasificar según sus arquitecturas y métodos de entrenamiento. Entre las más destacadas se encuentran Retrieval Augmented Generation (RAG) y fine-tuning. Ambas arquitecturas ofrecen ventajas complementarias, lo que las convierten en opciones populares en el desarrollo de chatbots efectivos [2].

2.3.1. Retrieval Augmented Generation (RAG)

RAG combina la generación de lenguaje natural con la recuperación de información, enfocándose principalmente en una *knowledge base*¹. Cuando un usuario formula una pregunta, RAG utiliza *embeddings*² para identificar y recuperar las partes del *relevant knowledge*³ que son pertinentes a esa pregunta. Este conocimiento relevante se inyecta en el *prompt*⁴ enviado al modelo de lenguaje (LLM). El *prompt* incluye tanto la pregunta como el contexto relacionado, lo que permite a la LLM generar respuestas más precisas y contextualizadas. La incorporación de datos externos en este proceso enriquece el conocimiento del modelo en tiempo real y disminuye las posibilidades de *hallucinations*⁵—respuestas que, aunque parecen plausibles, son incorrectas. Además, RAG utiliza bases de datos vectoriales y la búsqueda semántica para recuperar información relevante, lo que mejora la precisión y relevancia de las respuestas del chatbot. Este enfoque es especialmente útil en situaciones donde se requiere información actualizada o especializada, como en consultas de productos o en el soporte técnico.

¹knowledge base [base de conocimiento].

²embeddings [representaciones vectoriales].

³relevant knowledge [conocimiento relevante].

⁴prompt [entrada o solicitud al modelo de lenguaje].

⁵hallucinations [alucinaciones].




FIGURA 2.1. Diagrama de flujo de una consulta en un chatbot con arquitectura RAG.

2.3.2. Fine-Tuning

El fine-tuning implica ajustar un modelo de lenguaje preentrenado en un conjunto de datos específico para mejorar su comportamiento en contextos particulares. Este proceso optimiza la efectividad del modelo en aplicaciones industriales específicas, como en medicina, derecho o ingeniería. Sin embargo, una desventaja del fine-tuning es que el modelo resultante puede quedar congelado en un estado particular, lo que limita su adaptabilidad a nuevos contextos sin un nuevo ciclo de entrenamiento. Aunque el fine-tuning proporciona respuestas más precisas en contextos específicos, también puede carecer de la flexibilidad de RAG, que permite incorporar datos contextuales en tiempo real.

2.3.3. Ventajas y desventajas de los modelos RAG y Fine-Tuning

Esta subsección presenta una comparación entre ambos modelos, que muestra sus ventajas y desventajas.

TABLA 2.1. Ventajas y desventajas de los modelos RAG y Fine-Tuning.

Modelo	Ventaja	Desventaja
RAG	■ Permite incorporar información contextual actualizada en tiempo real. ■ Reduce la probabilidad de alucinaciones al usar datos relevantes. ■ Mejora la precisión y relevancia de las respuestas del chatbot.	■ Requiere una infraestructura adecuada para la recuperación de información. ■ Dependencia de la calidad y disponibilidad de la base de datos. ■ Puede ser más complejo de implementar y mantener.
Fine-Tuning	■ Mejora la calidad de las respuestas al adaptar el modelo a un dominio específico. ■ Proporciona un rendimiento más consistente en contextos bien definidos. ■ Permite la optimización de la latencia al trabajar con un modelo entrenado.	■ El modelo se congela en el tiempo y no se adapta a cambios contextuales. ■ Requiere un conjunto de datos específico para el entrenamiento, lo que puede ser costoso. ■ Menor flexibilidad para abordar consultas inesperadas o no entrenadas.

Capítulo 3

Diseño e implementación

3.1. Diseño de la arquitectura

3.1.1. Propuestas de implementación

Durante el desarrollo del sistema se realizaron cuatro versiones principales, cada una marcando un cambio relevante en la tecnología, la arquitectura o el enfoque funcional del chatbot. A continuación, se describen cada una de estas iteraciones:

Versión 0 - RAG básico con Pinecone

La necesidad inicial era construir un prototipo funcional para validar la arquitectura RAG utilizando herramientas accesibles.

Descripción: se implementó una arquitectura RAG elemental con una LLM (GPT-3.5-turbo) y el servicio de vectorstore Pinecone. El flujo básico consistía en pre-procesar documentos, generar embeddings, almacenarlos en Pinecone y recuperar los chunks relevantes a partir de la pregunta del usuario con el objetivo de construir un prompt enriquecido que sería enviado a la LLM.

Problemas detectados: aunque Pinecone ofrecía un buen desempeño en la recuperación de información, su costo por consulta representaba un obstáculo considerable para su adopción en entornos de producción. Además, la trazabilidad del sistema era limitada, ya que no existían mecanismos para evaluar la calidad de los chunks obtenidos ni auditar el proceso de recuperación.

Esto puso de manifiesto la necesidad de un sistema de almacenamiento local que permitiera un mayor control sobre la generación, almacenamiento y recuperación de los embeddings. Asimismo, se requerían herramientas que facilitaran tanto la evaluación de las respuestas como la auditoría del flujo completo de recuperación de contextos reelevantes.

Versión 1 - Integración de DSPy, migración a LanceDB y uso de NemoGuardrails

Razón del cambio: mejorar la calidad de las respuestas, reducir costos de infraestructura y establecer una capa de control conversacional previa a la ejecución del pipeline RAG.

Descripción: en esta versión se reemplazó Pinecone por LanceDB, una base de datos de vectores que permite almacenamiento local y ofrece mayor control sobre la estructura y acceso a los embeddings, eliminando costos asociados a servicios externos.

Se integró DSPy, un framework que permite definir prompts de manera modular y declarativa, lo que facilitó una implementación más mantenible de la arquitectura RAG.

También se añadió una capa de filtrado con Nemo Guardrails para bloquear preguntas fuera de dominio, y un sistema de evaluación automática que puntuaba las respuestas del LLM, permitiendo monitorear su rendimiento. Estos componentes fueron implementados como módulos independientes en DSPy, mejorando la modularidad y claridad del sistema.




FIGURA 3.1. Diagrama general del sistema para la versión 1.

Problemas detectados: aunque se logró una mayor robustez y control, surgieron varios desafíos. Nemo Guardrails mostró un rendimiento limitado en español y escasa capacidad de personalización, debido a su fuerte orientación al inglés, lo que redujo la eficacia del filtrado y motivó la búsqueda de alternativas más flexibles.

Además, si bien se incorporó un sistema de evaluación automática, aún no se contaba con trazabilidad completa de las interacciones ni con segmentación por métricas, aspectos que se abordarían en versiones posteriores.

Versión 2 - Guardrails personalizados, almacenamiento estructurado de chats e implementación del frontend y backend de pruebas

Razón del cambio: necesidad de mayor precisión en el filtrado y mejor trazabilidad de las conversaciones.

Descripción: se reemplazó Nemo Guardrails por una implementación propia, basada en LLMs livianos y reglas personalizadas escritas en código con prompts propios, lo que permitió mayor flexibilidad y una mejor adaptación al idioma español. Además, se comenzó a almacenar localmente la conversación completa de cada usuario incluyendo preguntas, respuestas y contexto previo en la memoria RAM de manera local. Esto dotó al sistema de memoria conversacional, mejorando la coherencia de las respuestas y habilitando análisis posteriores sobre el

historial de interacción. En paralelo, todas las interacciones del asistente (preguntas, respuestas, errores y rechazos por guardrails) comenzaron a registrarse en una base de datos NoSQL, lo que facilitó la trazabilidad de cada una de las interacciones de usuarios y el análisis detallado del comportamiento conversacional.




FIGURA 3.2. Diagrama general del sistema para la versión 2.

Problemas detectados: aunque el nuevo sistema de guardrails ofreció mayor control, la forma en la que se persistían los historiales de conversación generó un aumento significativo en el uso de memoria RAM, lo que limitó la escalabilidad del sistema. Además, la latencia de respuesta aumentó considerablemente, lo que afectó la experiencia del usuario. Por último, si bien el almacenamiento de las conversaciones facilitó el contexto en interacciones encadenadas, se detectó que para casos en los que la pregunta dependía de la pregunta anterior, los contextos no eran claros. Ejemplo:

- Usuario: "¿Tienen Stock del producto X?"
- Robot: "Sí, tenemos stock del producto X."
- Usuario: "¿Cuánto cuesta?"
- Robot: "Podrías aclarar de qué producto hablas?"

En este caso, el sistema no pudo identificar que la pregunta se refería al producto mencionado en la pregunta anterior. Esto evidenció la necesidad de un sistema de redefinición de preguntas que pudiera enriquecer el contexto y mejorar la recuperación de información utilizando palabras clave que referencien el contexto de la conversación.

Versión 3 - Integración de Langfuse, clasificación y evaluación automática

Razón del cambio: necesidad de un sistema robusto para trazabilidad, evaluación y mejora continua.

Descripción: se integró Langfuse como sistema observador no intrusivo para registrar todas las interacciones del sistema. además, se añadieron dos nuevas tareas en la capa de guardrails: la primera, redefinir preguntas, genera una nueva oración con palabras clave para buscar los contextos en la vectorestore; la segunda tarea, clasificar consultas, organiza las preguntas según su temática, como por

ejemplo Productos, Precios, Delivery, Queja, Saludo, entre otras. También se eliminaron bases de datos auxiliares, centralizando la gestión de la trazabilidad en Langfuse, que ahora se encarga de registrar todos los eventos: consultas, respuestas, errores, rechazos por guardrails, consumo de tokens, costos, latencia, etc.



FIGURA 3.3. Ejemplo de redefinición de pregunta.

Problemas detectados: algunos temas, como las quejas, mostraron un rendimiento inferior, lo que sugiere la necesidad de expandir y refinar el contexto disponible en versiones futuras.

3.1.2. Problemas y mitigaciones

Durante las primeras iteraciones surgieron limitaciones clave: costos por servicios externos (Pinecone, API de LLMs), pobre trazabilidad del sistema, y ausencia de control sobre la evaluación de calidad. Estos problemas se mitigaron mediante:

- **Migración a LanceDB para almacenamiento local sin costo.** LanceDB es una base de datos vectorial optimizada para uso local. Su adopción permitió eliminar la dependencia de servicios como Pinecone, que implicaban costos por cada consulta. Esta decisión fue especialmente útil durante la etapa de desarrollo y pruebas, ya que redujo los costos operativos. Sin embargo, se observó que LanceDB puede presentar latencias más altas en comparación con soluciones SaaS (software as a service), lo cual debe considerarse en entornos de producción. Por otra parte, para aplicaciones a gran escala, su uso local podría representar un ahorro sustancial al evitar tarifas por tokens o uso de APIs externas.
- **Uso de DSPy para estructurar la lógica RAG y mejorar la modularidad.** DSPy es una biblioteca que permite construir y optimizar pipelines de IA

mediante una programación declarativa. Se utilizó para implementar de manera modular el sistema RAG, definiendo claramente etapas de recuperación y generación. Esta implementación facilitó la trazabilidad del proceso completo, permitiendo auditar tanto la recuperación de contextos como la generación de respuestas. Además, su enfoque declarativo simplificó el desarrollo, mejorando la mantenibilidad y facilitando la introducción de mejoras incrementales al sistema.

- **Reemplazo de Nemo Guardrails por guardrails personalizados.** NeMo Guardrails no ofrecía resultados adecuados para preguntas en español. Por este motivo, se diseñó una solución propia basada en prompts simples con modelos LLM. Esta implementación personalizada fue capaz de detectar y filtrar preguntas sobre política, religión y temas sensibles. Además, se utilizó como etapa inicial para la clasificación temática y la redefinición de preguntas en etapas posteriores.
- **Incorporación de Langfuse como observador centralizado y sistema de métricas.** Langfuse es una herramienta de observabilidad que permite registrar, analizar y etiquetar cada interacción con el modelo. Su integración aportó trazabilidad completa del sistema, facilitó el monitoreo de métricas clave (como latencia, consumo de tokens, respuestas generadas) y habilitó la evaluación automática mediante la implementación de agentes de evaluación con IA en su plataforma. Gracias a esta integración, se logró una visión integral del rendimiento del sistema, permitiendo identificar áreas de mejora y optimizar el flujo de trabajo. Gracias a esta capacidad, se procedió a eliminar la etapa de DSPy que se encargaba de la evaluación automática, posterior a la respuesta de la LLM. Esto disminuyó la latencia del sistema y permitió una mejor trazabilidad de las interacciones, ya que Langfuse almacena todos los eventos generados por el sistema, incluyendo la evaluación automática. Esto permite auditar el funcionamiento del sistema y mejorar el contexto disponible en la etapa de análisis de métricas.

3.1.3. Elección de la arquitectura de chatbot

La arquitectura final del chatbot se fundamenta en el enfoque RAG (Retrieval-Augmented Generation), una técnica que ha demostrado ser altamente efectiva para responder preguntas contextualizadas sin necesidad de realizar un reentrenamiento completo del modelo de lenguaje (LLM). Esta decisión se basó en la necesidad de ofrecer un sistema flexible, escalable y de bajo costo operativo, especialmente orientado a pequeñas empresas y emprendedores que requieren soluciones ágiles y sostenibles.

El uso de RAG permite mantener el modelo LLM independiente de la base de conocimiento, lo que significa que se pueden incorporar nuevos documentos, actualizaciones o correcciones simplemente modificando los datos almacenados en el vectorstore, sin necesidad de ajustar los parámetros del modelo. Esta separación entre el modelo y la información facilita enormemente las tareas de mantenimiento y mejora continua del sistema.

Esta arquitectura RAG se seleccionó por ofrecer un equilibrio óptimo entre precisión, costo y mantenibilidad. Durante el desarrollo del proyecto, OpenAI lanzó GPT-4o mini, un modelo que presentaba un excelente balance entre rendimiento y economía, con capacidades superiores a las alternativas locales disponibles en ese

momento. Si bien se evaluó la posibilidad de implementar un modelo local con Ollama, la combinación de GPT-4o mini con LanceDB resultó ser más eficiente en términos de costo-beneficio, ya que eliminaba la necesidad de infraestructura adicional para hospedar y mantener modelos locales. Esta decisión permitió reducir significativamente el costo por consulta mientras se mantenía un alto estándar de calidad en las respuestas, haciendo que la solución fuera más accesible para pequeñas empresas y emprendedores. Adicionalmente, el uso de componentes modulares como DSPy facilitó que el sistema pudiera adaptarse fácilmente a nuevos modelos o proveedores de LLMs en el futuro, sin necesidad de rediseñar toda la arquitectura.

3.2. Arquitectura final propuesta

La arquitectura final del sistema está diseñada para ofrecer una solución robusta, eficiente y fácilmente escalable para la automatización de respuestas contextuales. Está compuesta por los siguientes bloques funcionales:

- **Frontend:** interfaz renovada para usuarios y administradores. Permite enviar preguntas al sistema, visualizar respuestas, acceder a métricas y gestionar los contextos mediante un formulario ilustrativo.



FIGURA 3.4. Frontend del chatbot.

- **Backend:** implementado en FastAPI, se encarga de recibir los request del frontend para procesar las preguntas, enviar las respuestas, procesar las métricas requeridas y actualizar los contextos en la base de datos de vectores. Gestiona el flujo completo de la conversación, registrando cada interacción, clasificando temáticamente las preguntas, redefiniéndolas usando el historial de mensajes previos, y preparando la consulta para la lógica RAG. Además, se encarga de procesar las métricas leyendo las trazas de Langfuse, analizando patrones de uso, calculando estadísticas de rendimiento y enviando estos análisis al frontend para que este los ilustre mediante gráficos y dashboards interactivos, facilitando así la visualización de tendencias y áreas de mejora del sistema.
- **Guardrails:** módulo de filtrado y preprocesamiento que evalúa si una consulta es válida (según reglas predefinidas), la clasifica en categorías como "Producto", "Quejas", "Saludos"; y la redefine incorporando el contexto de los mensajes anteriores.

- **DSPy RAG**: es el corazón del sistema, responsable de orquestar la lógica principal del flujo RAG. DSPy toma la pregunta ya enriquecida desde el módulo de guardrails y ejecuta una búsqueda eficiente de contextos relevantes en LanceDB. A partir de los fragmentos recuperados, construye un prompt enriquecido que será enviado al modelo LLM para generar una respuesta coherente y precisa. Además de facilitar la integración de prompts, DSPy permite definir y estructurar toda la lógica del sistema de recuperación y generación, proporcionando un marco flexible y modular para el diseño del flujo completo.
- **Langfuse**: observador pasivo que registra todas las interacciones del sistema sin intervenir. Almacena información crítica como la pregunta original, la redefinida, el consumo de tokens, la respuesta final y los estados de los guardrails. También permite aplicar evaluaciones automáticas sobre precisión de las respuestas generadas por el sistema.




FIGURA 3.5. Diagrama general del flujo del pipeline.

3.2.1. Tecnologías suplementarias

- **Streamlit**: utilizado para construir el frontend inicial de pruebas, permitiendo interacción simple del chat, que luego fue migrada a ReactJS.
- **Lovable**: lovable.dev es una herramienta online que permite crear frontends de forma rápida y sencilla con la ayuda de Inteligencia Artificial. Fue utilizada para crear la version final del frontend utilizando ReactJS, permitiendo una experiencia de usuario más fluida y atractiva. Además en ella se integraron las visualizaciones de las métricas generadas a partir de los datos de Langfuse.
- **Azure Container Apps**: Plataforma de Azure utilizada para desplegar el backend y el frontend del sistema en containers individuales. Permite escalar automáticamente los recursos según la demanda, asegurando un rendimiento óptimo en todo momento.

3.2.2. Funcionamiento general

El pipeline del sistema está diseñado para ofrecer una experiencia conversacional precisa, eficiente y trazable. A continuación se detalla el flujo completo de funcionamiento desde la perspectiva funcional:

1. El usuario realiza una consulta a través del **frontend**.

2. La consulta es enviada al **backend**, donde primero pasa por un sistema de **guardrails personalizados**. Aquí se ejecutan tres procesos clave:
 - **Filtrado**: se descartan preguntas fuera del dominio del sistema (por ejemplo, política o religión), basándose en reglas definidas.
 - **Clasificación**: la pregunta se categoriza automáticamente en una temática (Producto, Quejas, Saludos, etc.).
 - **Redefinición**: utilizando el historial conversacional completo, la pregunta se reformula para enriquecer su significado y contexto.
3. La pregunta redefinida es ingresada al primer modulo de DSPy donde es utilizada para buscar en **LanceDB**, los fragmentos de contexto indexados previamente que estan relacionados a la pregunta en cuestion.
4. La información obtenida se utiliza para construir un **prompt estructurado en el siguiente modulo de DSPy**. Esta es la etapa lógica mas importante del pipeline ya que aqui se encuentra el corazon del sistema RAG, en esta etapa es donde se integra tanto el contexto recuperado como la consulta original para preparar la entrada final al LLM.
5. El prompt es enviado a un **modelo LLM** (en este caso GPT-4o mini).
6. La respuesta y todos los datos asociados (estado del guardrail, redefinición, tokens consumidos, clasificación, etc.) son registrados por **Langfuse**.
7. En Langfuse, se ejecuta una **evaluación automática**, la cual analiza la calidad y asigna puntajes en una escala de 1 a 10, donde las puntuaciones bajas (menores a 3) indican respuestas que solo reformulan la pregunta o evidencian insuficiencia de contexto. Los criterios de evaluación son:
 - **Precisión**: determina si la respuesta aborda directamente la pregunta del usuario o simplemente la reformula sin proporcionar información sustancial.
 - **Suficiencia de contexto**: evalúa si la respuesta demuestra que el sistema disponía de información adecuada para contestar con propiedad o si indica explícitamente la falta de contexto necesario.
8. En paralelo con la observación de Langfuse, la respuesta es devuelta al usuario en el frontend.




FIGURA 3.6. Diagrama de flujo de funcionamiento.

3.3. Implementación

3.3.1. Preparación de los datos de contexto

La base de conocimiento utilizada por el sistema no proviene de documentos extensos procesados en chunks, sino de una estructura de tipo clave-valor diseñada específicamente para búsquedas contextuales rápidas y precisas. Cada entrada contiene dos campos principales:

- **question:** una lista de términos, sinónimos o expresiones relacionadas que representan la intención del usuario. este campo actúa como una clave semántica para la búsqueda.
- **relates:** una serie de frases informativas asociadas a la clave, que constituyen el contexto que será devuelto al modelo como parte del proceso RAG.

CÓDIGO 3.1. Ejemplo de estructura de datos clave-valor para el contexto

```

context = [
    {
        question: [
            queja ,
            reclamo ,
            problema ] ,

        relates: [
            Lamentamos que hayas tenido una mala
            experiencia. Por favor cuéntanos mas
            sobre tu situacion , Estamos aqui
            para ayudarte con cualquier
            inconveniente que hayas tenido
        ]
    },
    {

```

```

        question: [
            producto ,
            características ,
            especificaciones ],

        relates: [
            Nuestro producto cuenta
            con las siguientes características ,
            Las especificaciones técnicas son
        ]
    }
]

```

Durante la interacción, el sistema utiliza un LLM para reformular la consulta del usuario e identificar las claves más relevantes, luego estas keywords son utilizadas por LanceDB para ser comparadas con el conjunto `question`. A partir de esta coincidencia semántica y vectorial (la búsqueda es híbrida), se recuperan los valores correspondientes desde el campo `relates`, que son luego inyectados como contexto en el prompt del LLM generador.

3.3.2. Sistema de reentrenamiento con historiales y evaluación automatizada de interacciones

A lo largo del desarrollo del sistema, se adoptó un enfoque alternativo al reentrenamiento tradicional de modelos de lenguaje (LLM), priorizando la adaptabilidad continua mediante mecanismos de evaluación automática y actualización contextual. Esta arquitectura permite que el sistema analice los resultados de las interacciones con los usuarios sin modificar directamente los parámetros internos del modelo base.

En lugar de reentrenar el LLM, se mantiene un ciclo de mejora continua alimentado por datos conversacionales reales. Estos datos son organizados, evaluados y analizados a través de herramientas automatizadas. El administrador es responsable de revisar las métricas generadas y decidir si es necesario realizar ajustes en el sistema, gestionando los contextos almacenados en la base de datos vectorial LanceDB, a través del frontend en la interfaz de administración.

Evaluación automatizada y extracción de métricas

Cada interacción registrada en el sistema genera una “traza” que es almacenada mediante Langfuse. Estas trazas contienen no solo los mensajes de entrada y salida, sino también metainformación crucial: costo (tokens consumidos y dinero gastado), etiquetas temáticas (por dominio o tipo de consulta), comentarios evaluativos y puntajes de calidad (en una escala del 1 al 10).

Las evaluaciones son gestionadas por un proceso automatizado que recorre todas las trazas válidas (excluyendo categorías genéricas como "Saludos", "Otros"), e identifica aquellas que contienen puntuaciones explícitas ("trace.scores"). El código utilizado implementa un control de tasa (rate limit) y asegura la integridad del dataset.




FIGURA 3.7. Diagrama de flujo de observación de métricas.




FIGURA 3.8. métricas por categoría.

CÓDIGO 3.2. Fragmento de código para extracción y evaluación de trazas desde Langfuse

```
for trace in all_traces:
    ...
    if trace.scores and 'Saludo' not in trace.tags:
        score = trace.scores[0]
        traces_df = traces_df.append({...})
```

Procesamiento y análisis de calidad

Una vez recolectadas, las trazas se analizan mediante un pipeline estructurado:

1. **Preprocesamiento del texto:** Se normalizan las preguntas (minúsculas, eliminación de acentos y símbolos).
2. **Asociación temática:** Se agrupan por etiquetas temáticas estandarizadas.
3. **Evaluación cuantitativa:** Se asignan y procesan puntajes de calidad, calculando promedios, desviaciones estándar y clasificando las preguntas como buenas ≥ 8 , malas <5 , mejores y peores.
4. **Agrupamiento semántico:** Se transforman las preguntas en vectores de embeddings y se agrupan con HDBSCAN para detectar redundancias y patrones.
5. **Síntesis por grupo:** Se selecciona una pregunta representativa por cada grupo y se genera un resumen por etiqueta temática.



FIGURA 3.9. Ejemplo frontend, metricas para preguntas buenas y malas

Este análisis permite generar reportes automáticos por versión del sistema. Las métricas agregadas permiten evaluar el impacto de cada iteración del sistema. Durante las diferentes versiones, se registraron las siguientes métricas:

3.4. Despliegue de la interfaz de pruebas

Se implementó una interfaz interactiva mediante **ReactJS**, diseñada para facilitar tanto pruebas de usuario como análisis administrativo. Esta interfaz permite:

- Realizar preguntas al chatbot y visualizar respuestas en tiempo real.

- Consultar métricas de evaluación automática y categorías temáticas asignadas a cada pregunta.
- Modificar o agregar fragmentos de contexto a través de un formulario de carga.
- Acceder a las trazas generadas por Langfuse para cada interacción.

The image shows a web interface for managing chatbot contexts. It is divided into two main panels: 'Contexto Actual' (Current Context) and 'Agregar Contexto' (Add Context).

Contexto Actual: This panel displays the current context information. It includes a title 'TITULO:' followed by a description: '## Atención, contacto, ayuda, dudas, consultas, información, disponibilidad, servicios, horarios, sugerencias'. Below this, there is a section 'Atención:' with a list of four items: 1. Si necesitas ayuda o más información, escribinos Estamos aquí para lo que necesites. 2. ¿Tenés dudas sobre nuestros servicios? Contactanos y te daremos todos los detalles. 3. Estamos disponibles para vos y tu mascota todos los días Consultá nuestros horarios y ubicaciones. 4. Queremos escuchar tus consultas y sugerencias. Estamos para ayudarte. Below the list, there is a section '## Ubicación, contacto, dirección, teléfono, email, sitio web, información de contacto' and a section 'Ubicación y Contacto:' with the following details: Visitanos en Av. Mascotas Felices 123, Buenos Aires, Argentina. Contactános al +54 11 5555-1234. Envíanos un correo a contacto@petargboutique.com. Explora más en http://petargboutique.com.

Agregar Contexto: This panel is used to add new context. It has a 'Titulo' field with the placeholder 'Ingresa un título descriptivo'. Below it is a 'Descripción / Contenido' field with the placeholder 'Agrega información detallada que el chatbot utilizará para responder preguntas'. At the bottom of this panel is a blue button labeled 'Agregar'.

FIGURA 3.10. frontend creado para administracion de contextos.

Está pensada como una herramienta versátil que permite validar mejoras y cambios del sistema en producción de forma inmediata.

Capítulo 4

Ensayos y resultados

En este capítulo se presentan las pruebas realizadas al chatbot desarrollado, los resultados obtenidos en diferentes escenarios, los procesos de optimización aplicados y un análisis detallado del comportamiento observado. Finalmente, se identifican fallos relevantes y se proponen posibles mejoras para futuras iteraciones del sistema.

4.1. Evaluación de escenarios del chatbot

Esta sección describe las pruebas realizadas al chatbot en distintos escenarios representativos. El objetivo es observar su comportamiento y desempeño en situaciones típicas de uso, así como frente a entradas no esperadas o complejas.

4.1.1. Escenario 1: Interacción básica

Se evalúa la capacidad del chatbot para responder de manera coherente a preguntas simples y directas, típicas de un usuario promedio. Se espera verificar la fluidez, naturalidad y precisión en respuestas básicas.

4.1.2. Escenario 2: Manejo de errores

Este escenario considera la interacción con entradas incompletas, ambiguas o mal redactadas. Se analiza la habilidad del chatbot para detectar errores, pedir aclaraciones o corregir las respuestas en función del contexto.

4.1.3. Escenario 3: Consultas complejas

Aquí se prueban preguntas que requieren razonamiento más profundo o que involucran múltiples pasos. El objetivo es evaluar hasta qué punto el sistema puede gestionar tareas que van más allá de una interacción sencilla.

4.2. Optimización

En esta sección se detallan los procesos de optimización llevados a cabo para mejorar el rendimiento del chatbot. Esto incluye ajustes tanto en los parámetros del modelo como en la configuración del entorno de ejecución.

4.2.1. Ajuste de parámetros del modelo

Se describen los cambios realizados en los parámetros del modelo de lenguaje (por ejemplo, temperatura, top-k, top-p), justificando su elección en función de los resultados obtenidos.

4.2.2. Configuraciones del entorno de ejecución

Se documentan las modificaciones en el entorno técnico (hardware, uso de aceleradores, recursos del servidor, etc.) que influyeron en el rendimiento general del sistema.

4.2.3. Impacto en el rendimiento

Se analizan los efectos de las optimizaciones aplicadas, incluyendo mejoras en tiempo de respuesta, calidad de las respuestas y reducción de errores.

4.3. Análisis de resultados

Esta sección ofrece una interpretación crítica de los resultados obtenidos durante las pruebas. Se emplean métricas cuantitativas y cualitativas para comparar el comportamiento del chatbot en los distintos escenarios.

4.3.1. Métricas de evaluación

Se presentan y explican las métricas utilizadas para evaluar el rendimiento del sistema, como precisión, tiempo de respuesta y tasa de error.

4.3.2. Comparación entre escenarios

Se contrastan los resultados obtenidos en los distintos escenarios de prueba, identificando patrones de desempeño, fortalezas y debilidades.

4.3.3. Interpretación de resultados

Se interpreta el significado de los resultados y se reflexiona sobre los factores que pudieron influir en el comportamiento observado. Esta sección sirve como base para las propuestas de mejora.

TABLA 4.1. Resultados comparativos de evaluación del chatbot.

Escenario	Precisión (%)	Tiempo de respuesta (s)	Tasa de error (%)
Escenario 1	92.3	1.2	3.4
Escenario 2	85.6	1.8	7.1
Escenario 3	78.4	2.4	10.6

4.4. Identificación de fallos y mejoras propuestas

A partir de los ensayos realizados, esta sección presenta los errores más relevantes identificados durante las pruebas, así como propuestas concretas para mejorar el desempeño y la robustez del chatbot en el futuro.

4.4.1. Principales errores detectados

Se enumeran y describen los errores más significativos observados durante las pruebas, tales como respuestas incorrectas, ambigüedad o fallos de reconocimiento.

4.4.2. Limitaciones del sistema actual

Se discuten las limitaciones técnicas o de diseño que restringen las capacidades del sistema actual y que podrían abordarse en futuras versiones.

4.4.3. Sugerencias para mejoras futuras

Se presentan recomendaciones para superar los errores y limitaciones detectadas, proponiendo estrategias de mejora a nivel de modelo, arquitectura o interfaz.

Bibliografía

- [1] IBM. *Natural Language Processing (PLN)*.
<https://www.ibm.com/mx-es/topics/natural-language-processing>.
Accedido el 17 de septiembre de 2024. 2023.
- [2] Cobus Greyling. *RAG vs Fine-Tuning*.
<https://cobusgreyling.medium.com/rag-fine-tuning-e541512e9601>.
Accedido el 20 de septiembre de 2024. 2023.